

# CAGD(1) | 插值与逼近

## 1. 插值

### 1.1. 插值问题的描述

#### 1.1.1. 问题的一般形式

- 寻找定义域  $\Omega \subseteq \mathbb{R}^d$ , 值域  $\mathbb{R}$  上的函数  $f: \Omega \rightarrow \mathbb{R}$
- 基函数集合:  $B = \{b_1, \dots, b_n\}$ ,  $b_i: \Omega \rightarrow \mathbb{R}$
- 将  $f$  表示为基函数的线性组合

$$f_\lambda(x) = \sum_{k=0}^n \lambda_k b_k(x)$$


其中,  $f$  由  $\lambda = \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_n \end{pmatrix}$  唯一确定

- 函数值  $\{(x_1, y_1), \dots, (x_n, y_n)\}$ ,  $(x_i, y_i) \in \mathbb{R}^d \times \mathbb{R}$
- 目标找到  $\lambda$  使得  $f_\lambda(x_i) = y_i$  对所有  $i$  成立

#### 1.1.2. 插值问题应用举例

最简单的光滑曲线曲面建模问题:

- 给定曲线或曲面上的一组点
- 选择一组可张成合适函数空间的基函数
  - 光滑基函数
  - 任意线性组合也为光滑函数
- 找到一个线性组合能够使得曲线或曲面能插值给定点



## 1.2. 插值问题的求解

构造线性方程组:

- 在数据点  $x_i$  上计算基函数:

$$\forall i \in \{1, \dots, n\}: \sum_{i=1}^n \lambda_i b_i(x_i) = y_i$$

- 写成矩阵形式:

$$\begin{pmatrix} b_1(x_1) & \cdots & b_n(x_1) \\ \vdots & \ddots & \vdots \\ b_1(x_n) & \cdots & b_n(x_n) \end{pmatrix} \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_n \end{pmatrix} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$$

### 1.2.1. 多项式插值示例

- 使用多项式基  $B = \{1, x, x^2, x^3, \dots, x^{n-1}\}$
- 求解线性方程组

$$\begin{pmatrix} 1 & x_1 & \cdots & x_1^{n-1} \\ 1 & x_2 & \cdots & x_2^{n-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^{n-1} \end{pmatrix} \begin{pmatrix} \lambda_1 \\ \lambda_2 \\ \vdots \\ \lambda_n \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

### 1.2.2. 多项式插值存在的问题

- 系统矩阵稠密
- 依赖于基函数选取，矩阵可能病态，导致难以求解（求逆）

#### 病态问题

- 输入数据的细微变化导致输出（解）的剧烈变化
- 将线性方程看成直线（超平面）
  - 当系统病态时，直线编程近似平行
  - 求解（即直线求交）变得困难、不精确
- 举例：

- 考虑二元方程组

$$x_1 + 0.5x_2 = 1.5 \text{ 和 } 0.667x_1 + 0.333x_2 = 1$$

解为(1, 1)

- 对第二个方程右边项扰动0.001

$$x_1 + 0.5x_2 = 1.5 \text{ 和 } 0.667x_1 + 0.333x_2 = 0.999$$

解为(0, 3)

- 对矩阵系数进行扰动

$$x_1 + 0.5x_2 = 1.5 \text{ 和 } 0.667x_1 + 0.334x_2 = 0.999$$

解为(2, -1)

### 1.2.3. 矩阵条件数

$$\kappa_2(A) = \frac{\max_{x \neq 0} \frac{\|Ax\|}{\|x\|}}{\min_{x \neq 0} \frac{\|Ax\|}{\|x\|}}$$


- 等于最大特征值和最小特征值之间的比例
- 条件数大意味着基元之间有太多相关性

#### 考虑多项式插值

- 多项式插值问题是病态的
  - 对于等距分布的数据点  $x_i$ ，范德蒙矩阵的条件数随着数据点数  $n$  呈指数级增长（多项式最高次数为  $n-1$ ）

原因：

- 幂（单项式）函数基



- 幂函数之间差别随次数增加而减小
- 不同幂函数之间唯一差别为增长速度

#### 1.2.4. 函数互相抵消

- 对于单项式函数基，从左到右，首先由常函数1主宰，接着 $x$ 增长最快，接着 $x^2$ 增长最快，接着 $x^3$ 增长最快...
- 好的基函数一般需要系数交替以达到函数的互相抵消

解决方法：

- 使用正交多项式基
- 正交基获得方法：Gram-Schmidt正交化

### 1.3. 拉格朗日插值方法

拉格朗日插值方法避免求解线性方程组

#### 1.3.1. 拉格朗日插值的一般形式

- 构造插值问题的通用解
  - 给定 $n+1$ 个点 $\{(x_0, y_0), \dots, (x_n, y_n)\}$ ，寻找一组次数为 $n$ 的多项式基函数 $l_i$ 使得

$$l_i(x_j) = \begin{cases} 1, & \text{若 } i = j \\ 0, & \text{若 } i \neq j \end{cases}$$

- 插值问题的解为

$$P(x) = y_0 l_0(x) + y_1 l_1(x) + \dots + y_n l_n(x) = \sum_{i=0}^n y_i l_i(x)$$

#### 1.3.2. 拉格朗日多项式的计算

- $n$ 阶多项式，且有以下 $n$ 个根

$$x_0, x_1, x_2, \dots, x_{i-1}, x_{i+1}, \dots, x_n$$

- 可表示为

$$\begin{aligned} l_i(x) &= C_i (x - x_0)(x - x_1) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_n) \\ &= C_i \prod_{j \neq i} (x - x_j) \end{aligned}$$

- 由 $l_i(x_i) = 1$ ，可得

$$1 = C_i \prod_{j \neq i} (x_i - x_j) \Rightarrow C_i = \frac{1}{\prod_{j \neq i} (x_i - x_j)}$$

- 最终的多项式基函数为

$$l_i(x) = \frac{\prod_{j \neq i} (x - x_j)}{\prod_{j \neq i} (x_i - x_j)}$$

多项式 $l_i(x)$ 称为**拉格朗日多项式**

### 1.3.3. 拉格朗日插值 vs 单项式基插值

事实上，给定同一组输入点，利用拉格朗日多项式和利用范德蒙矩阵（单项式基）进行插值所得到的解完全相同

- 假设解不同。记两个解的差别多项式为  $R_n$ ， $R_n$  阶数至多为  $n$
- 那么  $R_n(x_i) = 0$ ， $i = 0, 1, \dots, n$ ， $x_i$  为不同插值点。因此  $R_n$  是有  $n + 1$  个根的  $n$  阶多项式，因此  $R_n = 0$

### 1.3.4. 多项式插值分析

- 多项式插值不稳定
- 控制点的微小变化可导致完全不同的结果
- 振荡现象：多项式随着插值点数（可以是细微的）增加而摆动

解决方法：

- 使用更好的基函数做插值，例如：分片多项式

## 2. 逼近

### 2.1. 动机

#### 2.1.1. 使用逼近的原因

- 数据点含噪声（采样）
- 更紧凑的表达
- 计算简单

#### 2.1.2. 常用的逼近函数

- 多项式
- 有理函数（多项式商）
- 三角函数

### 2.2. 多项式逼近

#### 2.2.1. 万能逼近定理

又叫Weierstrass定理：

令 $f$ 为闭区间 $[a, b]$ 上任意连续函数，则对任意给定 $\varepsilon$ ，存在 $n$ 和多项式 $P_n$ 使得

$$|f(x) - P_n(x)| < \varepsilon, \forall x \in [a, b]$$

Weierstrass只证明了存在性，而未给出多项式

#### 2.2.2. Bernstein多项式逼近

Bernstein多项式构造定理

对 $[0, 1]$ 区间上任意连续函数 $f(x)$ 和任意正整数 $n$ ，以下不等式对所有 $x \in [0, 1]$ 成立

$$|f(x) - B_n(f, x)| < \frac{9}{4} m_{f,n}$$

- $m_{f,n} = \text{lower upper bound } |f(y_1) - f(y_2)|$   
 $y_1, y_2 \in [0, 1] \text{ 且 } |y_1 - y_2| < \frac{1}{\sqrt{n}}$
- $B_n(f, x) = \sum_{j=0}^n f(x_j) b_{n,j}(x)$ ，其中 $x_j$ 为 $[0, 1]$ 上等距采样点
- $b_{n,j} = \binom{n}{j} x^j (1-x)^{n-j}$ 为Bernstein多项式

Bernstein多项式逼近特点

- 逼近结果优秀，但需要高阶
- 计算昂贵
- 容易带来误差

### 2.3. 最小二乘逼近

#### 2.3.1. 逼近问题

- 给定一组线性无关的连续函数集合 $B = \{b_1, \dots, b_n\}$ 和一组结点 $\{(x_1, y_1), \dots, (x_m, y_m)\}$ ，其中 $m > n$
- 在 $B$ 张成空间中寻找对结点逼近最好的函数 $f \in \text{span}(B)$

## 2.3.2. 最佳逼近的定义

### 最小二乘逼近

$$\begin{aligned} \operatorname{argmin}_{f \in \operatorname{span}(B)} \sum_{j=1}^m (f(x_j) - y_j)^2 \\ \sum_{j=1}^m (f(x_j) - y_j)^2 &= \sum_{j=1}^m \left( \sum_{i=1}^n \lambda_i b_i(x_j) - y_j \right)^2 \\ &= (M\boldsymbol{\lambda} - \mathbf{y})^T (M\boldsymbol{\lambda} - \mathbf{y}) \\ &= \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T M\boldsymbol{\lambda} + \boldsymbol{\lambda}^T M^T M\boldsymbol{\lambda} \end{aligned}$$

其中,  $\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \dots, \lambda_n)^T$ ,  $\mathbf{y} = (y_1, y_2, \dots, y_m)^T$ ,  $M = \begin{pmatrix} b_1(x_1) & \cdots & b_n(x_1) \\ \vdots & \ddots & \vdots \\ b_1(x_m) & \cdots & b_n(x_m) \end{pmatrix}$

### 2.3.3. 最小二乘解

- 关于 $\lambda$ 的二次多项式

$$\boldsymbol{\lambda}^T M^T M\boldsymbol{\lambda} - 2\mathbf{y}^T M\boldsymbol{\lambda} + \mathbf{y}^T \mathbf{y}$$

- 最小解满足

$$M^T M\boldsymbol{\lambda} = M^T \mathbf{y}$$